

TECH CHALLENGE — FASE 1

IADT — Inteligência Artificial e Data Transformation

Classificação de tumores de mama + EXTRA Visão Computacional
Wisconsin Breast Cancer & CNN (Pneumonia)

Participantes

Alexandre Aparecido Muniz Emygdio
Ana Clara Gouvêa Poubel
Rafael Evangelista da Silva
Samir Iago Souza Góes
Diego Justino Amaral de Souza

Data: 30/06/2026

Repositório: <https://github.com/Rafael-Evangelista/tech-challenge-fiap>

1. Introdução e contexto



Rede de saúde feminina busca apoio à triagem de câncer de mama. Fase 1 (obrigatória): classificar tumores como malignos ou benignos com Machine Learning (dados estruturados). Fase EXTRA: visão computacional com CNN em imagens médicas (Pneumonia.ipynb). Ambas as soluções são apoio à decisão — não substituem o médico.

Dataset principal: Wisconsin Breast Cancer (569 amostras, 30 features). Arquivo: data/data.csv.

2. Análise exploratória de dados (EDA)


569 registros, 30 features após limpeza. 357 benignos (62,7%) e 212 malignos (37,3%). Sem nulos. Malignos tendem a núcleos maiores; há sobreposição entre classes.

Métrica	Valor
Amostras	569
Benignos	357 (62,7%)
Malignos	212 (37,3%)




3. Análise de correlação


21 pares com $|r| > 0,9$. Top com maligno: concave points_worst (0,79), perimeter_worst, area_worst. Redundância entre medidas de tamanho.



4. PCA (exploratório)

10 componentes explicam ~95% da variância. PCA exploratório; modelagem usou 30 features escaladas.






5. Pré-processamento

- $B \rightarrow 0$, $M \rightarrow 1$
- Split 80/20 estratificado: 455 treino / 114 teste
- StandardScaler (fit treino, transform teste)

6. Modelagem e resultados


Modelo	Accuracy	Precision	Recall	F1
Regressão Linear	96,49%	100%	90,48%	95,00%
Regressão Logística	96,49%	97,50%	92,86%	95,12%
Random Forest	97,37%	100%	92,86%	96,30%

Recall da classe maligna prioritário em triagem. Random Forest escolhido.



7. Explicabilidade

Top: area_worst, concave points_worst. SHAP em 50 casos (notebook seção 7).



8. Discussão crítica

Limitações: 569 casos Wisconsin; PCA não no pipeline; validação externa pendente. Uso clínico: apoio à decisão com revisão humana.

9. EXTRA — Visão Computacional (CNN)

O enunciado da Fase 1 prevê, como entrega EXTRA (nota adicional), diagnóstico com dados de imagem utilizando Redes Neurais Convolucionais (CNN), como mamografias ou outros exames de imagem relacionados à saúde feminina. O grupo implementou esta parte extra no notebook Pneumonia.ipynb.


O notebook notebooks/Pneumonia.ipynb implementa uma CNN (TensorFlow/Keras) para classificar radiografias de tórax (Chest X-Ray) em NORMAL ou PNEUMONIA, utilizando o dataset público Chest X-Ray Images (Pneumonia) do Kaggle. Embora o tema do desafio principal seja câncer de mama com dados estruturados, esta entrega EXTRA demonstra competência em visão computacional aplicada à triagem médica por imagem.

Pipeline do Pneumonia.ipynb:

- Download do dataset via Kaggle API (kaggle.json)
- EDA: contagem por classe e visualização de amostras
- Tratamento de desbalanceamento com class_weight
- CNN convolucional com data augmentation
- Treinamento com early stopping (até 20 épocas)
- Avaliação no conjunto de teste (624 imagens)

Métrica (teste)	Valor
Accuracy	85,58%
Recall (PNEUMONIA)	97,44%
Precision	82,61%
AUC	93,80%

Para triagem de pneumonia, o recall da classe positiva é prioritário — errar um caso de pneumonia (falso negativo) é mais grave que um falso positivo. O modelo alcançou recall de aproximadamente 97% no teste.



```
history = model.fit(
    train_generator,
    validation_data=val_generator,
    epochs=7
)
```

Epoch 1/7
131/131 — 57s 378ms/step - accuracy: 0.8045 - auc: 0.8209 - loss: 0.4276 - precision: 0.8221 - recall: 0.9403 - val_accuracy: 0.8859 - val_auc: 0.9438
Epoch 2/7
131/131 — 42s 325ms/step - accuracy: 0.8881 - auc: 0.9420 - loss: 0.2686 - precision: 0.9146 - recall: 0.9368 - val_accuracy: 0.8917 - val_auc: 0.9521
Epoch 3/7
131/131 — 44s 333ms/step - accuracy: 0.8998 - auc: 0.9529 - loss: 0.2424 - precision: 0.9279 - recall: 0.9381 - val_accuracy: 0.8811 - val_auc: 0.9418
Epoch 4/7
131/131 — 42s 320ms/step - accuracy: 0.9116 - auc: 0.9622 - loss: 0.2173 - precision: 0.9395 - recall: 0.9416 - val_accuracy: 0.9233 - val_auc: 0.9693
Epoch 5/7
131/131 — 42s 324ms/step - accuracy: 0.9192 - auc: 0.9678 - loss: 0.2022 - precision: 0.9444 - recall: 0.9471 - val_accuracy: 0.9195 - val_auc: 0.9731
Epoch 6/7
131/131 — 43s 330ms/step - accuracy: 0.9262 - auc: 0.9706 - loss: 0.1898 - precision: 0.9474 - recall: 0.9535 - val_accuracy: 0.9252 - val_auc: 0.9756
Epoch 7/7
131/131 — 43s 325ms/step - accuracy: 0.9257 - auc: 0.9746 - loss: 0.1810 - precision: 0.9494 - recall: 0.9506 - val_accuracy: 0.9338 - val_auc: 0.9767

```
test_loss, test_acc, test_precision, test_recall, test_auc = model.evaluate(test_generator)
print(f"Teste accuracy: {test_acc * 100:.2f}% Teste loss: {test_loss:.4f}")
```

20/20 — 3s 152ms/step - accuracy: 0.8686 - auc: 0.9446 - loss: 0.3688 - precision: 0.8468 - recall: 0.9641
Teste accuracy: 86.86% Teste loss: 0.3688

Também disponível no repositório: [notebooks/02_cnn_mamografias.ipynb](#), com CNN para detecção em mamografias (dataset CBIS-DDSM), desenvolvido como trabalho complementar de visão computacional.

- docs/Análise dos resultados de pneumonia.pdf — relatório detalhado da parte EXTRA
- docs/figuras/raio-x.png — amostras de raio-x do notebook
- docs/figuras/resultados.png — curvas de treinamento e métricas

10. Entregáveis e execução

Item	Local / observação
Repositório Git	https://github.com/Rafael-Evangelista/tech-challenge-fiap
Notebook	notebooks/01_analise_e_modelagem.ipynb
Dataset	data/data.csv
Dependências	requirements.txt
README	Instruções de clone, branch e execução
Vídeo (até 15 min)	https://youtu.be/bGNR-eNHkK