

TECH CHALLENGE — FASE 1

IADT — Inteligência Artificial e Data Transformation

Classificação de tumores de mama (benigno vs maligno)
Saúde e segurança da mulher — Wisconsin Breast Cancer Dataset

Participantes

Alexandre Aparecido Muniz Emygdio
Ana Clara Gouvêa Poubel
Rafael Evangelista da Silva
Samir Iago Souza Góes
Diego Justino Amaral de Souza

Data: 30/06/2026

Repositório Git: <https://github.com/Rafael-Evangelista/tech-challenge-fiap>

1. Introdução e contexto

Uma rede de hospitais e centros de saúde especializados no atendimento à mulher busca apoio tecnológico para triagem e identificação precoce de riscos, incluindo câncer de mama. Nesta Fase 1, foi desenvolvida uma solução inicial de Machine Learning capaz de classificar tumores como malignos (M) ou benignos (B) a partir de medidas numéricas de núcleos celulares.

Objetivo: construir pipeline de EDA, pré-processamento, modelagem e explicabilidade, servindo como ferramenta de apoio à decisão clínica — sem substituir o médico.


Dataset: Wisconsin Breast Cancer (569 amostras, 30 features + diagnosis). Arquivo local: data/data.csv. Fonte sugerida no enunciado FIAP/Kaggle.


2. Análise exploratória de dados (EDA)

O dataset possui 569 registros e 33 colunas originais. Após limpeza, removeu-se a coluna id (identificador) e Unnamed: 32 (100% vazia), restando 30 variáveis preditivas numéricas.

Métrica	Valor
Total de amostras	569
Benignos (B)	357 (62,7%)
Malignos (M)	212 (37,3%)
Valores ausentes (features)	0

Não há desbalanceamento severo entre classes; técnicas de balanceamento não foram aplicadas nesta versão. Outliers foram mantidos por representarem tumores reais maiores ou mais agressivos. Boxplots e histogramas indicam que tumores malignos tendem a apresentar valores maiores em medidas de tamanho (raio, perímetro, área) e concavidade.






3. Análise de correlação



A matriz de correlação revelou forte redundância entre medidas de tamanho (radius, perimeter, area), com 21 pares com $|r| > 0,90$. As variáveis mais correlacionadas com o diagnóstico maligno concentram-se nas medidas worst e mean de tamanho e concavidade.

Variável	Correlação c/ maligno
concave points_worst	0,794
perimeter_worst	0,783
radius_worst	0,777
area_worst	0,734
area_mean	0,709



4. Análise de Componentes Principais (PCA)

O PCA foi utilizado de forma exploratória para avaliar redundância entre atributos. Aproximadamente 95% da variância total é explicada por 10 componentes principais (de 30 originais), confirmando multicolinearidade. Na modelagem final, utilizaram-se as 30 features escaladas, sem PCA no pipeline.



5. Pré-processamento e separação treino/teste

Pipeline aplicado em Python (notebook 01_analise_e_modelagem.ipynb):

- Codificação do alvo: $B \rightarrow 0$, $M \rightarrow 1$
- Separação estratificada 80/20 (random_state=42): 455 treino / 114 teste
- StandardScaler: fit apenas no treino, transform no teste (evita data leakage)
- Entrada dos modelos: 30 features padronizadas (média ≈ 0 , desvio ≈ 1 no treino)


6. Modelagem e resultados

Foram treinados três algoritmos, conforme exigência do enunciado (≥ 2 técnicas): Regressão Linear (com limiar 0,5), Regressão Logística e Random Forest (100 árvores, random_state=42).

Modelo	Accuracy	Precision	Recall	F1
Regressão Linear	96,49%	100%	90,48%	95,00%
Regressão Logística	96,49%	97,50%	92,86%	95,12%
Random Forest	97,37%	100%	92,86%	96,30%


Escolha da métrica: em triagem de câncer de mama, o recall da classe maligna é prioritário — classificar um tumor maligno como benigno (falso negativo) é mais grave que um falso positivo. Os três modelos obtiveram recall entre 90% e 93% no teste.

O Random Forest apresentou melhor acurácia geral (97,37%) e F1 (96,30%). Acurácia no treino foi 100% e no teste 97,37% (diferença de 2,63 p.p.), sem overfitting severo. A Regressão Linear, apesar do bom desempenho, não é ideal para classificação (previsões contínuas + limiar).



7. Explicabilidade (feature importance e SHAP)

A importância das variáveis no Random Forest destacou `area_worst`, `concave points_worst` e `perimeter_worst`, coerente com a análise de correlação. Foi aplicado SHAP (TreeExplainer) em amostra de 50 casos do teste para visualizar o efeito individual das features na classe maligna.



Nota: gráfico SHAP completo disponível no notebook Jupyter (seção 7). Valores em vermelho tendem a puxar a previsão para maligno.

8. Discussão crítica e uso clínico

Limitações

- Dataset pequeno (569 casos) e de contexto específico (Wisconsin, época/geografia únicas).
- PCA exploratório não foi integrado ao pipeline de treino.
- SHAP calculado em subamostra — resultado indicativo, não conclusivo.
- Modelo não validado externamente em outros hospitais ou populações.

Uso na prática

O sistema pode apoiar a triagem e priorização de casos suspeitos, reduzindo tempo de análise inicial. Porém, o médico deve sempre ter a palavra final: casos duvidosos e falsos negativos exigem revisão humana, exames complementares e protocolo clínico completo.

9. EXTRA — Visão Computacional (CNN)

O enunciado da Fase 1 prevê, como entrega EXTRA (nota adicional), diagnóstico com dados de imagem utilizando Redes Neurais Convolucionais (CNN). O grupo implementou esta parte extra exclusivamente no notebook Pneumonia.ipynb.


O notebook notebooks/Pneumonia.ipynb implementa uma CNN (TensorFlow/Keras) para classificar radiografias de tórax (Chest X-Ray) em NORMAL ou PNEUMONIA, utilizando o dataset público Chest X-Ray Images (Pneumonia) do Kaggle.

Pipeline do Pneumonia.ipynb:

- Download do dataset via Kaggle API (kaggle.json)
- EDA: contagem por classe e visualização de amostras
- Tratamento de desbalanceamento com class_weight
- CNN convolucional com data augmentation
- Treinamento com early stopping (até 20 épocas)
- Avaliação no conjunto de teste (624 imagens)

Métrica (teste)	Valor
Accuracy	85,58%
Recall (PNEUMONIA)	97,44%
Precision	82,61%
AUC	93,80%

Para triagem, o recall da classe pneumonia é prioritário. O modelo alcançou recall de aproximadamente 97% no teste.




```
history = model.fit(
    train_generator,
    validation_data=val_generator,
    epochs=7
)
```

... Epoch 1/7
131/131 — 57s 378ms/step - accuracy: 0.8045 - auc: 0.8209 - loss: 0.4276 - precision: 0.8221 - recall: 0.9403 - val_accuracy: 0.8859 - val_auc: 0.9438
Epoch 2/7
131/131 — 42s 325ms/step - accuracy: 0.8881 - auc: 0.9420 - loss: 0.2686 - precision: 0.9146 - recall: 0.9368 - val_accuracy: 0.8917 - val_auc: 0.9521
Epoch 3/7
131/131 — 44s 333ms/step - accuracy: 0.8998 - auc: 0.9529 - loss: 0.2424 - precision: 0.9279 - recall: 0.9381 - val_accuracy: 0.8811 - val_auc: 0.9418
Epoch 4/7
131/131 — 42s 320ms/step - accuracy: 0.9116 - auc: 0.9622 - loss: 0.2173 - precision: 0.9395 - recall: 0.9416 - val_accuracy: 0.9233 - val_auc: 0.9693
Epoch 5/7
131/131 — 42s 324ms/step - accuracy: 0.9192 - auc: 0.9678 - loss: 0.2022 - precision: 0.9444 - recall: 0.9471 - val_accuracy: 0.9195 - val_auc: 0.9731
Epoch 6/7
131/131 — 43s 330ms/step - accuracy: 0.9262 - auc: 0.9706 - loss: 0.1898 - precision: 0.9474 - recall: 0.9535 - val_accuracy: 0.9252 - val_auc: 0.9756
Epoch 7/7
131/131 — 43s 325ms/step - accuracy: 0.9257 - auc: 0.9746 - loss: 0.1810 - precision: 0.9494 - recall: 0.9506 - val_accuracy: 0.9338 - val_auc: 0.9767

```
test_loss, test_acc, test_precision, test_recall, test_auc = model.evaluate(test_generator)
print(f"Teste accuracy: {test_acc * 100:.2f}% Teste loss: {test_loss:.4f}")
```

20/20 — 3s 152ms/step - accuracy: 0.8686 - auc: 0.9446 - loss: 0.3688 - precision: 0.8468 - recall: 0.9641
Teste accuracy: 86.86% Teste loss: 0.3688

- docs/Análise dos resultados de pneumonia.pdf
- docs/figuras/raio-x.png
- docs/figuras/resultados.png

10. Entregáveis e execução

Item	Local / observação
Repositório Git	https://github.com/Rafael-Evangelista/tech-challenge-fiap
Notebook	notebooks/01_analise_e_modelagem.ipynb
Dataset	data/data.csv
Dependências	requirements.txt
README	Instruções de clone, branch e execução
Vídeo (até 15 min)	https://youtu.be/bGNR-eNHkK

Como executar: `git clone` do repositório → `pip install -r requirements.txt` → `jupyter notebook notebooks/01_analise_e_modelagem.ipynb`