

TECH CHALLENGE — FASE 1

IADT — Inteligência Artificial e Data Transformation

Classificação de tumores de mama (benigno vs maligno)
Saúde e segurança da mulher — Wisconsin Breast Cancer Dataset

Participantes

Alexandre Aparecido Muniz Emygdio

Ana Clara Gouvêa Poubel

Rafael Evangelista da Silva

Samir Iago Souza Góes

Diego Justino Amaral de Souza

Data: 23/06/2026

Repositório Git: <https://github.com/Rafael-Evangelista/tech-challenge-fiap>

1. Introdução e contexto

Uma rede de hospitais e centros de saúde especializados no atendimento à mulher busca apoio tecnológico para triagem e identificação precoce de riscos, incluindo câncer de mama. Nesta Fase 1, foi desenvolvida uma solução inicial de Machine Learning capaz de classificar tumores como **malgnos (M)** ou **benignos (B)** a partir de medidas numéricas de núcleos celulares.

Objetivo: construir pipeline de EDA, pré-processamento, modelagem e explicabilidade, servindo como ferramenta de **apoio à decisão clínica** — sem substituir o médico.


Dataset: Wisconsin Breast Cancer (569 amostras, 30 features + diagnosis). Arquivo local: *data/data.csv*. Fonte sugerida no enunciado FIAP/Kaggle.


2. Análise exploratória de dados (EDA)

O dataset possui 569 registros e 33 colunas originais. Após limpeza, removeu-se a coluna *id* (identificador) e *Unnamed: 32* (100% vazia), restando 30 variáveis preditivas numéricas.

Métrica	Valor
Total de amostras	569
Benignos (B)	357 (62,7%)
Malignos (M)	212 (37,3%)
Valores ausentes (features)	0

Não há desbalanceamento severo entre classes; técnicas de balanceamento não foram aplicadas nesta versão. Outliers foram mantidos por representarem tumores reais maiores ou mais agressivos. Boxplots e histogramas indicam que tumores malignos tendem a apresentar valores maiores em medidas de tamanho (raio, perímetro, área) e concavidade.






3. Análise de correlação



A matriz de correlação revelou forte redundância entre medidas de tamanho (radius, perimeter, area), com 21 pares com $|r| > 0,90$. As variáveis mais correlacionadas com o diagnóstico maligno concentram-se nas medidas *worst* e *mean* de tamanho e concavidade.

Variável	Correlação c/ maligno
concave points_worst	0,794
perimeter_worst	0,783
radius_worst	0,777
area_worst	0,734
area_mean	0,709



4. Análise de Componentes Principais (PCA)

O PCA foi utilizado de forma **exploratória** para avaliar redundância entre atributos. Aproximadamente **95% da variância** total é explicada por **10 componentes principais** (de 30 originais), confirmando multicolinearidade. Na modelagem final, utilizaram-se as 30 features escaladas, sem PCA no pipeline.



5. Pré-processamento e separação treino/teste

Pipeline aplicado em Python (notebook *01_analise_e_modelagem.ipynb*):

- Codificação do alvo: B $\rightarrow$ 0, M $\rightarrow$ 1
- Separação estratificada 80/20 (random_state=42): 455 treino / 114 teste
- StandardScaler: fit apenas no treino, transform no teste (evita data leakage)
- Entrada dos modelos: 30 features padronizadas (média $\approx$ 0, desvio $\approx$ 1 no treino)


6. Modelagem e resultados

Foram treinados três algoritmos, conforme exigência do enunciado (≥ 2 técnicas): Regressão Linear (com limiar 0,5), Regressão Logística e Random Forest (100 árvores, random_state=42).

Modelo	Accuracy	Precision	Recall	F1
Regressão Linear	96,49%	100%	90,48%	95,00%
Regressão Logística	96,49%	97,50%	92,86%	95,12%
Random Forest	97,37%	100%	92,86%	96,30%


Escolha da métrica: em triagem de câncer de mama, o **recall da classe maligna** é prioritário — classificar um tumor maligno como benigno (falso negativo) é mais grave que um falso positivo. Os três modelos obtiveram recall entre 90% e 93% no teste.

O Random Forest apresentou melhor acurácia geral (97,37%) e F1 (96,30%). Acurácia no treino foi 100% e no teste 97,37% (diferença de 2,63 p.p.), sem overfitting severo. A Regressão Linear, apesar do bom desempenho, não é ideal para classificação (previsões contínuas + limiar).



7. Explicabilidade (feature importance e SHAP)

A importância das variáveis no Random Forest destacou *area_worst*, *concave points_worst* e *perimeter_worst*, coerente com a análise de correlação. Foi aplicado SHAP (TreeExplainer) em amostra de 50 casos do teste para visualizar o efeito individual das features na classe maligna.



Nota: gráfico SHAP disponível no notebook Jupyter (seção 7).

8. Discussão crítica e uso clínico

Limitações

- Dataset pequeno (569 casos) e de contexto específico (Wisconsin, época/geografia únicas).
- PCA exploratório não foi integrado ao pipeline de treino.
- SHAP calculado em subamostra — resultado indicativo, não conclusivo.
- Modelo não validado externamente em outros hospitais ou populações.

Uso na prática

O sistema pode apoiar a **triagem e priorização** de casos suspeitos, reduzindo tempo de análise inicial. Porém, o médico deve sempre ter a palavra final: casos duvidosos e falsos negativos exigem revisão humana, exames complementares e protocolo clínico completo.

9. Entregáveis e execução

Item	Local / observação
Repositório Git	https://github.com/Rafael-Evangelista/tech-challenge-fiap
Notebook	notebooks/01_analise_e_modelagem.ipynb
Dataset	data/data.csv
Dependências	requirements.txt
README	Instruções de clone, branch e execução

Vídeo (até 15 min)	YouTube/Vimeo — demonstração do fluxo (pendente)
--------------------	--

Como executar:

```
git clone do repositório → pip install -r requirements.txt → jupyter notebook  
notebooks/01_analise_e_modelagem.ipynb
```